

Proyecto Centinela · Fase 2 — Bitácora de uso responsable de IA

Esta bitácora registra las interacciones relevantes con IA generativa (Claude, Anthropic) durante el desarrollo de la Fase 2, con la decisión tomada frente a cada salida —Aceptada, Modificada o Rechazada— y su justificación. La entrada 5 constituye la auditoría a la IA exigida por la actividad: un fallo no trivial (fuga de datos por pareo artificial) detectado, documentado y corregido.

Nº	Qué se pidió	Qué devolvió la IA	Decisión	Justificación
1	Rama A: se pidió a la IA la estructura de un notebook de Transfer Learning con dos arquitecturas (ResNet50 y EfficientNet-B0) sobre el dataset de imágenes de agua.	Entregó el flujo por bloques: exploración, augmentation, partición 70/15/15, pre-extracción de features, entrenamiento de cabezas, matrices de confusión y Grad-CAM.	Aceptada	El código corrió de principio a fin y las métricas fueron coherentes (97–99% de exactitud). Se verificó con Grad-CAM que la red mira el agua y no el fondo.
2	Rama A: la IA sugirió hacer fine-tuning completo del backbone para 'exprimir' más exactitud.	Propuso descongelar todas las capas y reentrenar con lr bajo.	Rechazada	Con solo 512 imágenes, reentrenar 25,6 M de parámetros invita al sobreajuste. Se mantuvo Feature Extraction, decisión justificada por tamaño y similitud con ImageNet, como pide la actividad.
3	Rama B: se pidió el código de ventanas deslizantes (14 días) por estación, respetando el orden temporal, y la comparativa RNN/LSTM/GRU con hiperparámetros iguales.	Entregó la construcción del dataset secuencial, el escalado, los tres modelos y la tabla comparativa con ROC-AUC, recall, precisión y F1.	Aceptada	Se verificó que la partición no mezcla el futuro con el pasado y que las tres celdas usan hiperparámetros comparables (oculto 64, lr 0,001, batch 32).
4	Rama B: la comparativa mostró a la RNN simple prácticamente empatada con LSTM/GRU (0,9332 vs 0,9350) y la IA lo reportó sin explicación.	La primera conclusión generada afirmaba genéricamente que 'LSTM y GRU superan a la RNN', contradiciendo la tabla.	Modificada	Se corrigió la conclusión (el empate es esperable con ventanas de 14 pasos) y se exigió un anexo experimental que evidenciara el desvanecimiento por las dos vías que contempla la rúbrica.
5	AUDITORÍA — Rama C: la primera versión de la fusión, generada con apoyo de IA, alineaba las modalidades con $n = \min(\text{len}(\text{gru}), \text{len}(\text{cnn}))$, emparejando la ventana temporal i con la imagen i .	La fusión colapsó: ROC-AUC 0,3099 y recall 0,0 sobre apenas 78 muestras, con una conclusión de texto fijo que afirmaba lo contrario a los números.	Rechazada y corregida	Fallo no trivial: el truncamiento es un pareo artificial por muestra (fuga de datos señalada explícitamente en la actividad) y además evaluaba sobre un subconjunto minúsculo. Se rediseñó la rama completa: alineación simulada por condición observable (pH del día t , nunca la etiqueta futura), pools de imágenes disjuntos por partición,

				fusión de embeddings reales (2048+64), validación separada del test y ablación sobre las 9.879 ventanas completas. Resultado final honesto: la fusión empata en ROC-AUC (0,9289) y mejora precisión y exactitud.
6	Anexo de desvanecimiento: se pidió a la IA un experimento con secuencia sintética larga y traza de normas de gradiente.	El primer diseño falló dos veces: con señal ± 3 la RNN 'memorizaba por saturación' del tanh y resolvía la tarea; con pesos sin entrenar, también LSTM/GRU mostraban gradientes desvanecidos.	Modificada	Se rediseñó con criterio propio: señal moderada (± 1) que impide la saturación, T = 100, inicialización de compuertas recomendada por Jozefowicz et al. (2015), y normas de gradiente medidas sobre los modelos ya entrenados retropropagando desde el logit crudo. Resultado limpio: RNN 49,8% (azar) con gradiente cero en t=0; LSTM 100% con gradiente íntegro; GRU 99,5% con nota interpretativa sobre saturación de compuertas.
7	Migración del entorno: se pidió adaptar el Bloque 1 de la Rama C para Colab con insumos en Google Drive (ZIP con imágenes, .mat y pesos).	Entregó un bloque que monta Drive, busca el ZIP en todo MyDrive, descomprime a disco local por velocidad y verifica cada insumo con   antes de continuar.	Aceptada	Resolvió el FileNotFoundError de rutas relativas y dejó el notebook reproducible en cualquier sesión de Colab.
8	Informe técnico: se pidió la redacción del informe (máx. 8 páginas) con metodología, resultados, ablación, limitaciones y recomendaciones al cliente.	Entregó el documento en Word con tablas, figuras embebidas y citación APA 7.	Modificada	Se verificaron todas las cifras contra las salidas reales de los notebooks, se ajustaron autores y se validó que la discusión reportara el hallazgo negativo (redundancia de la modalidad visual) sin maquillarlo.

Declaración de integridad

Los autores comprenden y pueden defender cada decisión de arquitectura, datos y métricas aquí documentada. El uso de IA se limitó a la generación y depuración de código, el diseño experimental y la redacción asistida; la validación de resultados, la detección del fallo de la entrada 5 y las decisiones metodológicas finales fueron responsabilidad del equipo.