

Proyecto Centinela · Fase 2

Informe técnico: del MLP al sistema multimodal especializado (CNN + GRU + fusión)

Camilo Chiquiza · Brian Lerma · Luz Villarraga — Julio de 2026

1. Resumen ejecutivo

El sistema Centinela del Río es una herramienta de alerta temprana que anticipa, con un día de antelación, si el agua de la fuente de abastecimiento de un acueducto comunitario rural (JAAR) quedará fuera del rango de pH seguro para consumo humano (6,5–8,5, guías OMS). En la Fase 1 el problema se resolvió con una línea base tabular (MLP). En esta Fase 2 el sistema evoluciona a una arquitectura multimodal especializada: una rama de visión por computador con Transfer Learning clasifica el estado visual del agua (Rama A), una rama recurrente modela la dinámica temporal de los indicadores físico-químicos (Rama B), y una capa de fusión tardía integra ambos flujos de información (Rama C).

Los resultados principales son: (i) la CNN preentrenada alcanza 97–99% de exactitud en la clasificación visual de tres estados del agua; (ii) el GRU logra un ROC-AUC de 0,9350 en la predicción de riesgo a un día, superando a la RNN simple y a la LSTM con menos parámetros que esta última; (iii) la fusión multimodal iguala la capacidad discriminativa de la mejor rama individual (ROC-AUC 0,9289) y mejora la precisión operativa (0,82 frente a 0,75) y la exactitud (86,1% frente a 83,9%), es decir, reduce las falsas alarmas al mismo nivel de detección. El estudio de ablación revela un hallazgo honesto: bajo la alineación simulada declarada, la modalidad visual aporta información mayormente redundante con la serie; su valor pleno exigirá un co-registro genuino en campo, propuesto para la Fase 3.

2. Datos y declaración de alineación entre modalidades

La rama temporal conserva la fuente de la Fase 1: Water Quality Prediction (UCI Machine Learning Repository, id 733; Zhao, 2019; licencia CC BY 4.0), con 37 estaciones de monitoreo, 705 días y 11 índices físico-químicos, de la cual se construyen ventanas deslizantes de 14 días (15.096 muestras de entrenamiento). La rama visual incorpora por primera vez la segunda modalidad: el Water Classification Dataset (Roboflow, CC BY 4.0), con 512 imágenes en tres categorías —Limpia (Bersih), Turbia (Keruh) y Contaminada (Kotor)—, que cumple el mínimo de 500 imágenes y 3 clases exigido por la actividad. Ninguna de las dos fuentes proviene de Kaggle.

La decisión metodológica más importante de esta fase es la clave de alineación. No existe una clave genuina por muestra entre las dos fuentes: la serie del UCI no trae imágenes y el dataset visual no registra fecha ni GPS por fotografía. En consecuencia, se declara una alineación simulada por condición observable: a cada ventana temporal se le asigna una imagen muestreada aleatoriamente del grupo cuya clase visual es coherente con el estado del agua en el último día de la ventana (pH dentro de rango → Limpia; pH fuera de rango → Turbia o Contaminada). La clave de emparejamiento es siempre el estado presente y observable en el momento de la predicción (día t), nunca la etiqueta objetivo (riesgo en $t+1$): emparejar con la etiqueta futura constituiría fuga de datos. Adicionalmente, las imágenes de entrenamiento y prueba provienen de particiones disjuntas (70/15/15, semilla fija), de modo que ninguna imagen de evaluación fue vista durante el entrenamiento. Se deja constancia de la limitación: la correlación imagen-serie es simulada, no medida en campo; los resultados de la fusión demuestran la arquitectura, y su valor real dependerá de un co-registro genuino (bocatoma, fecha) en la Fase 3.

3. Metodología

3.1 Rama A — Clasificación visual con Transfer Learning

Se compararon dos arquitecturas convolucionales preentrenadas en ImageNet: ResNet50 (25,6 M de parámetros, conexiones residuales; He et al., 2016) y EfficientNet-B0 (5,3 M de parámetros, escalado compuesto; Tan y Le, 2019). Dado el tamaño moderado del conjunto propio (512 imágenes) y su similitud parcial con ImageNet, se adoptó la estrategia de Feature Extraction: el backbone se congela y solo se entrena la cabeza de clasificación, lo que reduce el riesgo de sobreajuste. El preprocesamiento incluyó data augmentation (volteo horizontal, rotación y variación de color), partición 70/15/15 con semilla fija y early stopping. La interpretabilidad se verificó con Grad-CAM (Selvaraju et al., 2017), confirmando que la red fundamenta su decisión en la superficie del agua y no en el fondo de la escena.

3.2 Rama B — Serie temporal con redes recurrentes

Sobre las ventanas de 14 días se entrenaron, con hiperparámetros comparables (estado oculto 64, dos capas, lr 0,001, batch 32, early stopping y partición que respeta el orden temporal), tres celdas recurrentes: una RNN simple como contraste, una LSTM (Hochreiter y Schmidhuber, 1997) y una GRU (Cho et al., 2014). Ante el empate observado entre las tres celdas en ventanas cortas, se elaboró un anexo experimental que evidencia el desvanecimiento del gradiente por las dos vías que contempla la actividad: una tarea sintética de dependencia larga (la señal de clase vive únicamente en el primer paso de una secuencia de 100) y la traza de las normas de gradiente $\|\partial L / \partial x_t\|$ sobre los modelos entrenados, con la inicialización de compuertas recomendada por Jozefowicz et al. (2015).

3.3 Rama C — Fusión multimodal tardía

Se implementó la fusión tardía por concatenación de embeddings: el vector oculto del GRU (64 dimensiones) y el embedding del backbone ResNet50 (2.048 dimensiones) se concatenan y alimentan una cabeza densa (2.112 $\rightarrow$ 64 $\rightarrow$ 1) que emite el logit de riesgo. El entrenamiento usó BCEWithLogitsLoss con pos_weight para el desbalance, validación interna separada del conjunto de prueba y early stopping. El estudio de ablación comparó tres configuraciones sobre exactamente el mismo conjunto de prueba (9.879 ventanas): solo serie (GRU), solo imagen (cabeza lineal sobre el embedding visual) y el modelo fusionado. Cabe señalar, como ejercicio de auditoría al uso de IA, que una versión preliminar de esta rama emparejaba ventana i con imagen i por simple truncamiento de índices —un pareo artificial que constituye fuga de datos y que colapsaba la fusión (ROC-AUC 0,31)—; el fallo fue detectado, documentado en la bitácora y corregido con el diseño aquí descrito.

4. Resultados

4.1 Rama A

Ambas arquitecturas alcanzan desempeño sobresaliente en el conjunto de prueba (78 imágenes), con ROC-AUC de 0,9997. La Tabla 1 resume la comparación; la Figura 1 presenta las matrices de confusión y la Figura 2 la verificación Grad-CAM.

Modelo	Exactitud	ROC-AUC	F1 macro	Parámetros del backbone
ResNet50	97,4%	0,9997	0,96	25,6 M
EfficientNet-B0	98,7%	0,9997	0,97	5,3 M

Tabla 1. Comparación de arquitecturas CNN (Feature Extraction, conjunto de prueba).




Figura 1. Matrices de confusión de las dos CNN en el conjunto de prueba.




Figura 2. Grad-CAM (ResNet50): la activación se concentra en la superficie del agua, no en el fondo.

4.2 Rama B

En la tarea real, con dependencias de solo 14 pasos, las tres celdas quedan prácticamente empatadas (Tabla 2). El GRU obtiene el mejor ROC-AUC con un 25% menos de parámetros que la LSTM, y por ello se selecciona para el sistema. El anexo experimental explica el empate y sustenta la elección: en una dependencia de 99 pasos la RNN simple queda en el azar (49,8%) mientras LSTM y GRU alcanzan ~100% (Figura 3); en los modelos entrenados, el gradiente de la RNN hacia los primeros pasos es exactamente cero —desvanecimiento genuino por producto de Jacobianos—, mientras que en la LSTM llega íntegro hasta el primer paso gracias a la autopista del estado de celda.

Modelo	ROC-AUC	Recall riesgo	Precisión riesgo	F1 riesgo	Parámetros
RNN simple	0,9332	0,7599	0,7783	0,7690	13.313
LSTM	0,9306	0,7457	0,7700	0,7576	53.057
GRU	0,9350	0,7694	0,7586	0,7639	39.809

Tabla 2. Comparación de celdas recurrentes (ventana de 14 días, conjunto de prueba).




Figura 3. Evidencia del desvanecimiento: en una dependencia de 99 pasos, la RNN queda en el azar; las celdas con compuertas resuelven la tarea.

4.3 Rama C — Fusión y estudio de ablación

La Tabla 3 y la Figura 4 presentan la ablación sobre el mismo conjunto de prueba de 9.879 ventanas. La fusión iguala el ROC-AUC de la mejor rama individual (0,9289) y, en el umbral operativo, mejora la precisión de la clase de riesgo (0,8187 frente a 0,7500) y la exactitud global (86,1% frente a 83,9%), a costa de una leve reducción del recall (0,8249 frente a 0,8790). La rama visual aislada se comporta al nivel del azar (ROC-AUC 0,5022), lo que indica que, bajo la alineación simulada, el embedding de imagen no añade información discriminativa nueva respecto a la serie.

Configuración	ROC-AUC	Recall	Precisión	F1	Exactitud
Solo serie (GRU)	0,9289	0,8790	0,7500	0,8094	0,8390
Solo imagen (CNN)	0,5022	0,5215	0,3871	0,4443	0,4927
Fusión multimodal	0,9289	0,8249	0,8187	0,8218	0,8608

Tabla 3. Estudio de ablación (mismo conjunto de prueba, 9.879 ventanas).




Figura 4. Convergencia de la fusión (izquierda) y aporte de cada modalidad por ROC-AUC (derecha).

5. Discusión y limitaciones

El hallazgo central de la ablación se reporta con honestidad: la fusión no supera en capacidad discriminativa a la rama temporal. La explicación es directa y estaba anticipada en la declaración de alineación: la imagen asignada a cada ventana codifica el estado observable del día t , información que la serie ya contiene en sus propios indicadores; bajo un emparejamiento simulado, la modalidad visual resulta redundante. El resultado no es un fracaso de la arquitectura sino una lectura correcta de los datos disponibles: la cabeza de fusión aprende a apoyarse en la señal temporal y a usar la visual como regularización, lo que se refleja en la mejora de precisión y exactitud (menos falsas alarmas al mismo poder de ranking). Un resultado negativo bien analizado orienta mejor la inversión del cliente que una mejora artificiosa.

Las limitaciones principales son tres. Primera, la alineación simulada: el valor real de la modalidad visual solo podrá medirse con fotografías co-registradas en campo (misma bocatoma, misma fecha que la telemetría), levantamiento que se propone como actividad de la Fase 3. Segunda, el conjunto visual es moderado (512 imágenes) y de un contexto geográfico distinto al de la serie, lo que limita la generalización de la CNN a las condiciones locales del acueducto. Tercera, la serie del UCI está normalizada y anonimizada por estación, de modo que no incorpora variables exógenas locales (lluvias, festivos operativos) que podrían elevar el recall de la clase de riesgo.

6. Recomendaciones para el cliente (JAAR)

En lenguaje operativo: hoy el Centinela avisa con un día de anticipación y acierta la gran mayoría de las veces. De cada diez días realmente riesgosos detecta cerca de ocho, y con el sistema fusionado las alarmas que emite son más confiables: de cada diez alertas, ocho corresponden a riesgo real, frente a siete y media del modelo anterior, lo que reduce la fatiga de alarmas del fontanero. Se recomienda: (i) operar la alerta diaria con la rama temporal (GRU) como motor principal, manteniendo la arquitectura de fusión desplegada; (ii) iniciar en la Fase 3 un protocolo sencillo de fotografía diaria de la bocatoma con celular (misma hora, mismo encuadre), que generará en pocos meses el co-registro real imagen–telemetría que esta fase identificó como condición para que la cámara aporte

valor pleno; y (iii) priorizar el recall en la operación —es preferible verificar una alarma de más que omitir un día de agua insegura—, ajustando el umbral de decisión en temporada de lluvias.

7. Referencias

- Cho, K., van Merriënboer, B., Gulcehre, C., Bahdanau, D., Bougares, F., Schwenk, H., & Bengio, Y. (2014). Learning phrase representations using RNN encoder-decoder for statistical machine translation. arXiv:1406.1078.
- He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR).
- Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8), 1735–1780.
- Jozefowicz, R., Zaremba, W., & Sutskever, I. (2015). An empirical exploration of recurrent network architectures. Proceedings of the 32nd International Conference on Machine Learning (ICML).
- Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D., & Batra, D. (2017). Grad-CAM: Visual explanations from deep networks via gradient-based localization. Proceedings of the IEEE International Conference on Computer Vision (ICCV).
- Tan, M., & Le, Q. (2019). EfficientNet: Rethinking model scaling for convolutional neural networks. Proceedings of the 36th International Conference on Machine Learning (ICML).
- Baltrušaitis, T., Ahuja, C., & Morency, L.-P. (2019). Multimodal machine learning: A survey and taxonomy. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 41(2), 423–443.
- Zhao, L. (2019). Water Quality Prediction [Conjunto de datos]. UCI Machine Learning Repository. <https://doi.org/10.1145/3339823>